

Základy spojité optimalizace

Ladislav Láška

23. března 2010

Obsah

| | | |
|----------|--|----------|
| 1 | Úvod | 3 |
| 1.1 | Úloha, cílová funkce, množina řešení | 3 |
| 1.2 | Dělení na jednotlivé disciplíny optimalizace | 3 |
| 1.3 | Motivační úloha | 4 |
| 1.3.1 | Lineární programování | 4 |
| 1.3.2 | Celočíselné programování | 4 |
| 1.3.3 | Nelineární programování | 4 |
| 1.3.4 | Parametrické programování | 4 |
| 1.3.5 | Vícekriteriální programování | 5 |
| 1.3.6 | Dynamické programování | 5 |
| 2 | Volný extrém | 5 |
| 2.1 | Postačující podmínka | 5 |
| 2.2 | Penalizační metody | 5 |
| 2.3 | Bariérové metody | 6 |
| 2.4 | Penalizačně-bariérové (SUMT) | 6 |
| 3 | Metody hledání lokálního minima | 6 |
| 3.1 | Gradientní | 6 |
| 3.2 | Newtonova metoda | 7 |
| 3.3 | Lemkeho metoda | 7 |
| 4 | Lineární programování | 7 |
| 4.1 | Podprostor | 7 |
| 4.2 | Poloprostor | 8 |
| 4.3 | Rozklad konvexního polyedru | 9 |
| 4.4 | 1. Základní věta lineárního programování | 11 |
| 4.5 | Simplexová tabulka | 12 |
| 4.6 | Simplexová metoda | 13 |
| 4.7 | 1. věta Simplexové metody | 13 |
| 4.8 | 2. věta Simplexové metody | 13 |
| 4.9 | 3. věta Simplexové metody | 14 |
| 4.10 | Konečnost simplexové metody | 14 |
| 4.11 | Vznik degenerace | 15 |
| 4.12 | Odstranění cyklů/degenerace | 15 |
| 4.13 | Množina optimálních řešení | 15 |
| 4.14 | Výpočetní složitost simplexové metody | 16 |
| 4.15 | Jiné metody | 16 |
| 4.15.1 | Elipsoidová-Chačijanova metoda (1979) | 16 |
| 4.15.2 | Karmarkarova projekční metoda | 16 |
| 4.15.3 | Metody konvexního programování | 16 |

| | | |
|------|---|----|
| 4.16 | 2. základní věty lineárního programování: princip duality | 17 |
| 4.17 | Důsledky věty o dualitě | 18 |
| 4.18 | Různé typy úloh lineárního programování | 19 |

1 Úvod

1.1 Úloha, cílová funkce, množina řešení

Definice Úloha matematického programování (optimalizace) rozumíme úlohu

$$\min_{x \in M} f(x)$$

kde $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Definice Funkci $f(x)$ nazýváme **cílovou**, účelovou, kriteriální, objektivní funkcí.

Definice Množinu M nazýváme množinou přípustných řešení. Prvek $x \in M$ nazýváme přípustným řešením optimalizační úlohy. Prvek $x_0 \in M$ nazveme optimálním řešením.

1.2 Dělení na jednotlivé disciplíny optimalizace

1. Volný extrém - $\min_M f(x)$
2. Vázaný extrém - $\min_M f(x), M \subset \mathbb{R}^n$
 - (a) Lineární programování:
 $\min_M cx, M = \{x | A_x \{=, \leq, \geq\} b\}$, kde $c \in \mathbb{R}^n, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$
 - (b) Nelineární programování:
 $\min_M f(x), M = \{x | g_j(x) < 0 (j = 1, \dots, m)\}, f, g_j : \mathbb{R}^n \rightarrow \mathbb{R}$
 - i. Konvexní a zobecněné konvexní programování - f, g_j konvexní, dále pak kvadratické a hyperbolické programování
 - ii. Nekonvexní (speciální typy)
 - (c) Celočíselné programování:
Lineární/nelineární programování, navíc podmínky pro celočíselnost $Ax * b$, aby $x \in \mathbb{N}$.
 - (d) Parametrické programování:
Lineární/nelineární programování, navíc parametr $\min_{M(U)} c(\lambda)^T x, c(x) = c + C\lambda, M(U) = \{x | A(U)x * b(U)\}$
 - (e) Vícekriteriální (vektorové) programování:
 $\min_M f(x), f(x) = \{f_1(x), \dots, f_s(x)\}$
 - (f) Dynamické programování - hledání optimální strategie
 - (g) Spojité programování (optimalizační procesy)
 - (h) Teorie her - optimální strategie dvou hráčů
 - (i) Semidefinitní programování - nekonečně mnoho podmínek

1.3 Motivační úloha

1.3.1 Lineární programování

V_1, \dots, V_n - výrobci vyrábějící výrobek V v množstvích $a_i > 0$
 S_1, \dots, S_k - spotřebitelé požadující výrobek V v množstvích $b_j > 0$.
Známe cenu za dopravu jednotky výrobku V z V_i do S_j - $c_{i,j} \geq 0$.

Předpoklad: ceny za dopravu rostou lineárně.

Cíl: minimalizovat celkové náklady na dopravu.

Hledáme: množství $x_{i,j} \geq 0$ - kolik výrobce V_i dodá S_j .

Cílová funkce

$$f(x) = \sum_i \sum_j c_{i,j} x_{i,j} \quad (1)$$

na množině řešení

$$M = \{x_{i,j} \mid \sum_{i=1}^m x_{i,j} = b_j \forall j, \sum_{j=1}^m x_{i,j} = a_i \forall i, \sum_i a_i = \sum_j b_j, x_{i,j} \geq 0 \forall i \forall j\} \quad (2)$$

Všechno je lineární - úloha lineárního programování.

1.3.2 Celočíslené programování

Pokud nelze položky libovolně dělit (například lidi), můžeme přidat celočíselnou podmínku do množiny řešení:

$$x_{i,j} \in \mathbb{N}_0 \forall i \forall j \quad (3)$$

1.3.3 Nelineární programování

Zrušíme předpoklad lineárního růstu cen (tedy cena závisí na množství)

$$f(x) = \sum_i \sum_j c_{i,j}(x_{i,j}) x_{i,j} \quad (4)$$

$$c_{i,j} = C_{i,j} + c_{i,j} x_{i,j}$$

1.3.4 Parametrické programování

Produkce není pevná a závisí na parametru: $a_i = \lambda a'_i$. Ostatní vztahy můžou zůstat třeba jako u lineárního programování.

1.3.5 Vícekriteriální programování

Minimalizovat ceny za dopravu, maximalizovat zisky Z .

$$\min\{f(x), g(x)\} \quad (5)$$

$$f(x) = \sum_i \sum_j c_{i,j} x_{i,j} \quad (6)$$

$$g(x) = -Z(x_{i,j}) \quad (7)$$

1.3.6 Dynamické programování

Ceny závisí na rozhodnutí.

2 Volný extrém

Hledání $\min f(x)$.

2.1 Postačující podmínka

Jestliže má funkce $f(x)$ v $x_0 \in \mathbb{R}^n$ spojitě 2. parciální derivace, $\nabla f(x_0) = 0$, $\nabla^2 f(x_0)$ (Hessova matice) je pozitivně definitní, potom má reálná funkce $f(x)$ v x_0 ostré lokální minimum.

2.2 Penalizační metody

Máme úlohu

$$\min_M f(x), \quad M = \{x | g_j(x) \leq 0, j = 1, \dots, n\} \quad (1)$$

Hledáme penalizační funkci $p(x)$ vyjadřující pokutu za to, že pracujeme s $x \in M$. $p(x)$ je vytvořená z podmínek g_j a řešíme posloupnost úloh na volný extrém:

$$\min\{f(x) + \alpha_k p(x)\} \quad (2)$$

Po $p(x)$ požadujeme:

$$p(x) > 0 : \quad x \notin M \quad (3)$$

$$p(x) = 0 : \quad x \in M \quad (4)$$

$$p(x) \text{ spojitá} \quad (5)$$

Posloupnost takovýchto úloh za jistých okolností konverguje k optimálnímu řešení.

Příklad

$$\sum_{j=1}^n (g_j^+(x))^2, \quad g_j^+(x) = \max\{g_j(x), 0\} \quad (6)$$

2.3 Bariérové metody

Hledáme bariérovou funkci $b(x)$, která nám zabráni vystoupit z množiny M . Řešíme tedy posloupnost úloh:

$$\min\{f(x) + \frac{1}{\beta_k} b(x)\}, \quad \beta_k \rightarrow \infty \quad (1)$$

A po funkci $b(x)$ požadujeme:

$$b(x) \leq 0 : \quad x \in M \quad \lim_{x \rightarrow \partial M} b(x) = \infty \quad (2)$$

kde ∂M je hranice množiny.

Příklad

$$b(x) = - \sum_j \frac{1}{g_j(x)} \quad (3)$$

$$b(x) = - \sum_j \log(-g_j(x)) \quad (4)$$

2.4 Penalizačně-bariérové (SUMT)

Rozdělíme množinu $\{1 \dots m\}$ na I_1 disjunkt ní I_2 . Řešíme posloupnost úloh:

$$\min\{f(x) + \alpha_k \sum_{j \in I_1} \varphi(g_j(x)) + \frac{1}{\beta_k} \sum_{j \in I_2} \psi(g_j(x))\} \quad (1)$$

3 Metody hledání lokálního minima

3.1 Gradientní

Podle věty o přírůstku funkce funkce roste nejvíce ve směru gradientu:

$$f(x) = f(x_0) + \nabla f(x_0 + \theta(x - x_0))^T (x - x_0) \quad (1)$$

Počítáme:

$$x_{k+1} = x_k - \zeta \nabla f(x_k), \quad \text{kde } \zeta \text{ je řešením} \quad (2)$$

$$\min_{\zeta \leq 0} f(x_k - \zeta \nabla f(x_k)) \quad (3)$$

3.2 Newtonova metoda

$$f(x) \doteq f(x_k) + \nabla f(x_k)(x - x_k) + \frac{1}{2}(x - x_k)\nabla^2 f(x_k)(x - x_k) \quad (1)$$

$$\nabla f(x) = 0 \quad (2)$$

$$0 + \nabla f(x_k) + \nabla^2 f(x_k)(x - x_k) = 0 \quad (3)$$

$$x_{k+1} = x_k - \nabla f(x_k)(\nabla^2 f(x_k))^{-1} \quad (4)$$

$$x_1 = 0 \quad (5)$$

3.3 Lemkeho metoda

Nápad: vezmeme výchozí řešení x a vzdálenost ρ , metodou půlení přibližujeme.

Požadavky: $\{x | f(x) \leq f(x_1)\}$ je omezená.

Problém vhodně zvolit x_1 .

Metoda K x_1 sestavíme $x_1 + \rho e^i$ pro $\rho > 0$ a spočítáme funkční hodnoty $f(x_1 + \rho e_i)$ a porovnáme s funkční hodnotou v x_1 . Pokud:

$$1. f(x_1 + \rho e_i) \geq f(x_1) \quad \forall i \Rightarrow \rho = \frac{\rho}{2}$$

$$2. \exists j: y := f(x_1 + \rho e_j) < f(x_1) \Rightarrow \text{opakujeme pro } y$$

4 Lineární programování

Definice Úlohou pro lineární programování v rovnicovém tvaru rozumíme úlohu:

$$\min_M c^T x, \quad M = \{x | Ax = b, x \geq 0\}, \quad (1)$$

$$\text{kde } A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, c \in \mathbb{R}^n, \text{rank}(A) = m, 1 \leq m < n, b \geq 0 \quad (2)$$

Definice Úlohou lineárního programování normálním tvaru rozumíme

$$\min_M c^T x, M = \{x | Ax \leq b, x \geq 0\}, \quad (3)$$

$$\text{kde } A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, c \in \mathbb{R}^n, n, m \geq 1 \quad (4)$$

4.1 Podprostor

Tvrzení Množina

$$R = \{x \in \mathbb{R}^n | a^T x = b, a \neq 0\} \quad (1)$$

představuje podprostor dimenze $n - 1$ nazývaný **nadrovinou**.

Důkaz Protože $a \neq 0 \Rightarrow \exists a_1 \neq 0 \Rightarrow x_1 = \frac{b}{a_1} - \sum_{i=1}^n \frac{a_i}{a_1} x_i$. Tedy máme $n - 1$ LN vektorů v R .

Tvrzení Množina $R^{n-\alpha} = \{x \in \mathbb{R}^n | a_i^T x = b_i, i = 1 \dots \alpha\}$ představuje podprostor \mathbb{R}^n dimenze $n - \alpha$.

4.2 Poloprostor

Definice Pro libovolnou nadrovinu $R = \{x \in \mathbb{R}^n | a^T x = b, a \neq 0\}$ nazýváme:

1. $H^+ = \{x \in \mathbb{R}^n | a^T x > b\}$ otevřeným kladným (pravým) poloprostorem \mathbb{R}^n příslušným R .
2. $H^- = \{x \in \mathbb{R}^n | a^T x < b\}$ otevřeným záporným (levým) poloprostorem \mathbb{R}^n příslušným R .
3. $\overline{H^+} = \{x \in \mathbb{R}^n | a^T x \geq b\}$ uzavřeným kladným (pravým) poloprostorem \mathbb{R}^n příslušným R .
4. $\overline{H^-} = \{x \in \mathbb{R}^n | a^T x \leq b\}$ uzavřeným záporným (levým) poloprostorem \mathbb{R}^n příslušným R .

Tvrzení Platí:

1. $H^+ \cup H^- \cup R = \mathbb{R}^n$
2. $\overline{H^+} = H^+ \cup R, \overline{H^-} = H^- \cup R$
3. $H^+ \cap H^- = H^+ \cap R = H^- \cap R = \emptyset$

Tvrzení Platí:

$$\dim \mathcal{H}_i^+ = \dim \overline{\mathcal{H}_i^+} = n \quad (1)$$

$$\text{kde } \mathcal{H}_i^+ = \{x \in \mathbb{R}^n | x_i > 0\} \quad (2)$$

$$\overline{\mathcal{H}_i^+} = \{x \in \mathbb{R}^n | x_i \geq 0\} \quad (3)$$

Důkaz V každém takovém prostoru leží všechny jednotkové vektory.

Tvrzení Platí:

$$\dim \bigcap_{i=1}^n \overline{\mathcal{H}_i^+} = \dim \bigcap_{i=1}^n \mathcal{H}_i^+ = n \quad (4)$$

Důsledek Množina přípustných řešení lineárního programování:

$$M = \{x | Ax = b, x \geq 0\} \quad (5)$$

kde $b(A) = m, a \leq m < n$.

Taktéž lze zapsat jako:

$$M = \mathbb{R}^{n-m} \cap \bigcap_{i=1}^n \overline{\mathcal{H}_i^+} \quad (6)$$

Definice Každou množinu $M \subset \mathbb{R}^n$, která se dá popsat jako průnik konečného počtu nadrovin a uzavřených poloprostorů nazýváme konvexním polyedrem.

=====
=====

4.3 Rozklad konvexního polyedru

Označme:

$$R^{n-m} = \{x \in \mathbb{R}^n | Ax = b\} \quad (1)$$

$$R_\alpha = \{x \in \mathbb{R}^n | x_\alpha = 0\} \quad (2)$$

$$\mathcal{H}_\alpha^+ = \{x \in \mathbb{R}^n | x_\alpha > 0\} \quad \overline{\mathcal{H}_\alpha^+} = \{x \in \mathbb{R}^n | x_\alpha \geq 0\}, \alpha = 1, \dots, n \quad (3)$$

Potom:

$$M = R^{n-m} \cap \bigcap_{\alpha=1}^n \overline{\mathcal{H}_\alpha^+} = \mathbb{R}^{n-m} \bigcap_{\alpha=1}^n \mathcal{H}_\alpha^+ \cup R_\alpha = \quad (4)$$

$$= \left(R^{n-m} \cap \bigcap_{\alpha=1}^n \mathcal{H}_\alpha^+ \right) \cup \left(R^{n-m} \cap R_1 \cap \bigcap_{\alpha=1}^n \mathcal{H}_\alpha^+ \right) \cup \dots \quad (5)$$

Definice První člen rozkladu $(\mathbb{R}^n \cap \bigcap_{\alpha=1}^n \mathcal{H}_\alpha^+)$ nazýváme **vnitřkem** konvexního polyedru M . Ostatní členy rozkladu nazýváme hraniční, každý prvek hranice, tj.

$$\left(\mathbb{R}^{n-m} \cap \bigcap_{\alpha \in I_1} \mathcal{H}_\alpha^+ \cap \bigcap_{\alpha \in I_2} R_\alpha \right), \quad I_1 \cup I_2 = \{1, \dots, n\}, I_1 \cap I_2 = \emptyset \quad (6)$$

Pokud je $\neq 0$ a má dimenzi d , nazýváme stěnou M dimenze d . speciálně stěnu dimenze 0 nazýváme vrcholem M a stěnu dimenze 1 hranice M .

Tvrzení

$$\dim(\mathbb{R}^{n-m} \cap \bigcap_{\alpha=1}^n \mathcal{H}_{\alpha}^+) = n - m \quad (7)$$

1. $0 \leq \dim(\text{stěny}) \leq n - m - 1$
2. Stěn všech dimenzí je konečný počet.
3. Průnik libovolných 2 stěn $S_1 \cap S_2 = \emptyset$.
4. Uzávěr každé stěny dimenze d je konvexní polyedr dimenze d .

$$M = \{x \in \mathbb{R}^n | Ax = b, x \geq 0\} \quad (8)$$

Protože $\text{rank}(A) = m \Rightarrow \exists$ konečný počet $\text{rank}(A_B) = m, A_B \in \mathbb{R}^{m \times m}$ Označíme $A = (A_B A_N)$, kde A_B je regulární. Analogicky rozdělíme $x = (X_B, X_N)$. Pak můžeme přepsat rovnici $Ax = b \rightarrow A_B X_B + A_N X_N = b$, tedy

$$X_B = A_B^{-1}b - A_B^{-1}A_N X_N \quad (9)$$

Položíme-li všechny $X_N = 0$, získáváme jednoznačně určené $X_B = A_B^{-1}b$

Definice Prvek $x = (X_B, X_N) \in M$ s vlastností $X_B = A_B^{-1}b > 0, X_N = 0$ nazveme nedegenerovaným přípustným bázickým řešením úlohy lineárního programování.

Poznámka Přípustné (nedegenerované) bázické řešení má $n - m$ souřadnic rovných 0.

Definice B nazýváme **bází**, proměnné $x_{\alpha}, \alpha \in B$ nazýváme **bázickými** proměnnými a $x_{\alpha}, \alpha \in N$ **nebázickými** proměnnými.

Tvrzení Bází B je konečný počet. $|B| = m, |N| = n - m, B \cup N = \{1, \dots, n\}$

Poznámka Protože vrchol je množina

$$\mathbb{R}^{n-m} \cap \bigcap_{\alpha \in I_1} R_{\alpha} \cap \bigcap_{\alpha \in I_2} \mathcal{H}_{\alpha}^+ \quad (10)$$

a protože $I_1 \cup I_2 = \{1, \dots, n\}$ a $I_1 \cap I_2 = \emptyset$, potom jistě $|I_1| = n - m$, protože $R_{\alpha} = \{x \in \mathbb{R}^n | x_{\alpha} = 0\}$.

Tvrzení Geometrickému pojmu **vrchol** odpovídá algebraický pojem **přípustné nedegenerované bázické řešení**.

Tvrzení Konvexní polyedr má alespoň jeden vrchol.

Důkaz Z rozkladu M můžeme vybrat vždy $|I_1| = n - m$. $R_\alpha = \{x | x_\alpha = 0\}$, $\alpha \in \{1, \dots, n\}$, tedy aby

$$\mathbb{R}^{n-m} \cap \bigcap_{\alpha \in I_1} R_\alpha \cap \bigcap_{\alpha \notin I_1} \mathcal{H}_\alpha^+ \quad (11)$$

měla dimenzi 0.

4.4 1. Základní věta lineárního programování

Lemma Je-li $M \neq \emptyset$ omezený konvexní polyedr o vrcholech \mathbf{x}^i , $i = \{1, \dots, p\}$. Potom můžu psát

$$M = \{\mathbf{x} | A\mathbf{x} = \mathbf{b}\} = \{\mathbf{x} \in \mathbb{R}^n | \mathbf{x} = \sum_{i=1}^p x_i \mathbf{x}^i, x_i \geq 0, \sum_1^p x_i = 1\} \quad (1)$$

Věta Existuje-li řešení úlohy lineárního programování, pak je ho dosaženo alespoň v jednom vrcholu konvexního polyedru M .

Důkaz

1. Uvažujme, že M je omezený. Potom podle lemmatu platí pro $x \in M$ zápis:

$$\mathbf{x} = \sum_{i=1}^p x_i \mathbf{x}^i, x_i \geq 0, \sum_i x_i = 1 \quad (2)$$

pro

$$\mathbf{c}^T \mathbf{x} = \mathbf{c}^T \sum_{i=1}^p x_i \mathbf{x}^i = \sum_{i=1}^p x_i \mathbf{c}^T \mathbf{x}^i \quad (3)$$

Označíme-li:

$$\min_{i \in \{1, \dots, p\}} \mathbf{c}^T \mathbf{x}^i = \mathbf{c}^T \mathbf{x}^i \quad (4)$$

Potom můžeme psát

$$\mathbf{c}^T \mathbf{x} \geq \sum_{i=1}^p x_i \mathbf{c}^T \mathbf{x}^{i_0} = \mathbf{c}^T \mathbf{x}^{i_0} \quad (5)$$

2. Pokud je M neomezený, zvolíme $k \gg 0$ a definujeme omezený konvexní polyedr:

$$M^* = M \cup \{\mathbf{x} \in \mathbb{R}^n | 1^T \mathbf{x} \leq k\}, 1^T = (1, \dots, 1) \quad (6)$$

Pro k musí platit (abychom neodřízli vrchol):

$$k > \max_{i=\{1, \dots, k\}} \{1^T \mathbf{x}^T\} \quad (7)$$

Nyní podle 1. části důkazu existuje alespoň jeden vrchol M^* , který dává optimální řešení. Potom

- (a) Vrchol je v původní množině M , je tvrzení dokázáno.
- (b) Vrchol není v původní množině M , potom musí ležet na hraně původního polyedru M (protože jsme přidali jednu lineární rovnici). Každá hrana omezeného konvexního polyedru M^* vychází z nějakého vrcholu M . Z vlastností, že $\mathbf{c}^T \mathbf{x} > \mathbf{c}^T \mathbf{x}_{opt}$ plyne, že pro body této hrany $\{x | \mathbf{x}^1 + t(\mathbf{x}^{opt} - \mathbf{x}^1)\}$ s vlastností $t > 1$ platí, že $\mathbf{c}^T \mathbf{x} \rightarrow -\infty$ a neexistuje řešení dané úlohy.

4.5 Simplexová tabulka

Známe-li libovolnou bázi B , přepíšeme množinu

$$M = \{\mathbf{x} | A\mathbf{x} = \mathbf{b}, \mathbf{x} \geq 0\} = \{(\mathbf{x}_B, \mathbf{x}_N) \in \mathbb{R}^n | \mathbf{x}_B + A_B^{-1} A_N \mathbf{x}_N = A_B^{-1} \mathbf{b}, (\mathbf{x}_B, \mathbf{x}_N) \geq 0\} \quad (1)$$

Přípustné bázecké řešení je pak $\mathbf{x} = (\mathbf{x}_B, \mathbf{x}_N) = (A_B^{-1} \mathbf{b}, 0)$ a simplexová tabulka zachycující množinu M vypadá:

| | | | |
|----------------|----------------|-------------------------------|---------------------------|
| | \mathbf{x}_B | \mathbf{x}_N | |
| \mathbf{x}_B | E | $A_B^{-1} A_N$ | $A_B^{-1} \mathbf{b} > 0$ |
| | $0, \dots, 0$ | $\mathbf{c}_N - \mathbf{z}_N$ | $-\mathbf{c}_0$ |

A cílová funkce:

$$\mathbf{c} = (\mathbf{c}_B, \mathbf{c}_N) \quad (2)$$

$$\mathbf{c}^T \mathbf{x} = \mathbf{c}_B^T \mathbf{x}_B + \mathbf{c}_N^T \mathbf{x}_N = \mathbf{c}_B^T (A_B^{-1} \mathbf{b} - A_B^{-1} A_N \mathbf{x}_N) + \mathbf{c}_N^T \mathbf{x}_N \quad (3)$$

tedy

$$\forall x \in M \mathbf{c}^T \mathbf{x} = \mathbf{c}_0 + (\mathbf{c} - \mathbf{z}_N) \mathbf{x}_N \quad (4)$$

kde $\mathbf{c}_0 = \mathbf{c}^T (A_B^{-1} \mathbf{b}, 0)$

4.6 Simplexová metoda

1. $\min_M \mathbf{c}^T \mathbf{x}$
2. $M = \{x \in \mathbb{R}^n | Ax = b, x \geq 0\}, A \in \mathbb{R}^{m \times n}, h(A) = m, 1 \leq m < n, b \in \mathbb{R}^n, c \in \mathbb{R}^n$
3. $\mathbf{c}^T \mathbf{x}$ Předpokládejme, že při výpočtu simplexové metody nenastává degenerace.
4. (obecný k-tý krok) Máme simplexovou tabulku. Předpokládejme, že bážické řešení je

$$x^k = (x_B, x_N) = (d_0, o) \quad (1)$$

Množinu M a cílovou funkci přepíšeme:

$$M = \{x_0, x_N | x_B + Dx_N = d_0, x_B > 0, x_N \geq 0\} \quad (2)$$

$$c^T x = c_B^T x_B + c_N^T x_N = c_0 + (c_N - z_N)x_N \quad (3)$$

4.7 1. věta Simplexové metody

Věta Platí-li v k-tém kroku simplexové metody

$$c_N - z_N \geq 0 \quad (1)$$

v příslušné simplexové tabulce, potom je příslušné bážické řešení x^k optimální.

Důkaz

$$\forall x \in M : c^T x = c_0 + (c_N - z_N)x_N \geq c_0 = c^T x^k \quad (2)$$

4.8 2. věta Simplexové metody

Věta Existuje-li v k-tém kroku simplexové metody v simplexové tabulce index $h \in N$ tak, že $c_h - z_h < 0$ a příslušný h-tý sloupec matice D splňuje $d_h \leq 0$, potom je cílová funkce $c^T x$ zdola neomezená na množině M a tedy řešení neexistuje.

Důkaz Hrana M vycházející z vrcholu \mathbf{x}^k má popis $\{x | x_B = d_0 - td_h, x_j = 0, j \in N \setminus h, x_k = t \geq 0\}$

$$x \in h : c^T x = c_0 + \underbrace{(c_h - z_h)}_{<0} t \rightarrow -\infty \quad (1)$$

4.9 3. věta Simplexové metody

Věta Nejsou-li splněny předpoklady první ani druhé věty simplexové metody, potom definujeme (r je index v simplexové tabulce):

$$\min_j (c_j - z_j) = c_r - z_r \quad (1)$$

a hledáme

$$\min_{d_{ir} > 0} \left\{ \frac{d_{is}}{d_{ir}} \right\} = \frac{d_{s0}}{d_{sr}} \quad (2)$$

a po transformaci tabulky s pivotem d_{sr} získáme nové přípustné bážické řešení x^{k+1} s vlastností $c^T x^{k+1} < c^T x^k$

Značení r -tý sloupec nazýváme klíčovým sloupcem a s -tý řádek nazýváme klíčovým řádkem.

Důkaz Proměnná x_s se stane nebážickou a nebážická proměnná x_r se stane bážickou, tedy z s -té rovnice vypočítáme x_r a dosadíme za něj do ostatních rovnic i cílové funkce. (Gaussova eliminace)

Nová báze je $B' = (B \setminus \{s\}) \cup \{r\}$ a nebážické proměnné $B' = (B \setminus \{r\}) \cup \{s\}$ a nové přípustné bážické řešení (plyne z Gausse):

$$d'_0 : x_r^{k+1} = \frac{d_{s0}}{d_{sr}} > 0 \quad (3)$$

$$i \in B \setminus \{s\} : X_i^{k+1} = d_{i0} - \frac{d_{ir} d_{s0}}{d_{sr}} \quad (4)$$

$$x_s, x_j = 0, j \in N \setminus \{r\} \quad (5)$$

A ověříme přípustnost takového řešení:

$$1. \text{ Pokud } d_{ir} \leq 0 \Rightarrow x_i^{k+1} = d'_{i0} > 0$$

$$2. \text{ Pokud } d_{ir} > 0, \text{ potom ze (2) } \frac{d_{s0}}{d_{sr}} < \frac{d_{i0}}{d_{ir}} \Rightarrow d'_{i0} > 0$$

A cílová funkce se transformuje:

$$c^T x^{k+1} = c_0 + (c_r - z_r) \frac{d_{s0}}{d_{sr}} \quad (6)$$

4.10 Konečnost simplexové metody

Tvrzení Simplexová metoda se ukončí po konečném počtu kroků.

Důkaz Máme konečný počet bážických řešení a nelze se vracet (protože $\forall k : c^T x^{k+1} < c^T x^k$).

Poznámka V degenerovaném případě může nastat i rovnost a proto teoreticky může nastat cyklus.

4.11 Vznik degenerace

1. Zadáním - $\exists i : b_i = 0$
2. Pokud klíčový řádek není určen jednoznačně (je lineární závislý na jiném)

4.12 Odstranění cyklů/degenerace

1. Odstranění cyklů - **Blandovo pravidlo**: Volíme minimum ze všech indexů j nebázických, pro které je $c_j - z_j < 0$, $r := j$ (takovýto index je určen jednoznačně). Také s zvolíme jednoznačně:

$$s = \{\min t \mid \min_{d_{ir} > 0} \left\{ \frac{d_{i0}}{d_{ir}} \right\} = \frac{d_{t0}}{d_{tr}}\} \quad (1)$$

2. ε -modifikace: řešíme novou úlohu pro $\varepsilon > 0$.

$$\min_{M+\varepsilon} c^T x \quad (2)$$

$$M + \varepsilon = \{x_B x_N \mid x_B + D x_N = a_0 + (ED)\varepsilon, x_B x_N \geq 0\} \quad (3)$$

kde $\varepsilon = (\varepsilon, \varepsilon^2, \dots, \varepsilon^n)$.

Důkaz

1. (bez důkazu)
2. epsilonový vektor zaručuje, že jednotlivé složky nelze poměřit

4.13 Množina optimálních řešení

Definice Množinou všech optimálních řešení úlohy nazýváme:

$$M_{opt} = \{x^i \in M \mid \min_M c^T x = c^T x_i\} \quad (1)$$

Věta Je-li x^0 optimální řešení úlohy nalezené simplexovou metodou a $c_N - z_N, -c_0$ v posledním řádku poslední simplexové tabulky. Potom:

$$M_{opt} = \{x \in M \mid x_j = 0, j \in J\}, \quad (2)$$

$$\text{kde } J = \{j \in N \mid c_j - z_j > 0\} \quad (3)$$

Důkaz Máme optimální řešení a simplexovou tabulku z posledního kroku. $x^0 = (x_B, x_N) = (d_0, o)$.

$$\forall x \in M : \quad c^T x = c_0 + (c_N - z_N)x_N = c_0 + \sum_{j \in J} (c_j - z_j)x_j + \sum_{j \notin J} \underbrace{(c_j - z_j)}_{=0} x_j = c_0 \quad (4)$$

Když položíme rovnost 0, tedy $x_j = 0, j \in J$.

Poznámka Změna hodnoty cílové funkce po jedné transformaci tabulky

$$-c'_0 = -c_0 - \frac{c_r - z_r) \cdot d_{s0}}{d_{sr}} \quad (5)$$

4.14 Výpočetní složitost simplexové metody

Mějme výpočet simplexovou metodou, kde n a m je počet rovnic a bazických proměnných.

1. Nejhorší odhad počtu kroků je dán počtem bazí, tedy $\binom{n}{m}$.
2. Na pravděpodobnostních modelech byl ukázán odhad

$$P(n, m) \leq m^{\frac{1}{n-1}} \cdot (n+1)^n \cdot \frac{2}{5} \pi \left(1 + \frac{e\pi}{2}\right) \quad (1)$$

3. Výpočetní zkušenosti (p = počet kroků)
 - (a) Počet kroků nezávisí na n a je mezi $2m - 3m$
 - (b) $p < \frac{3}{2}m$

4.15 Jiné metody

4.15.1 Elipsoidová-Chačijanova metoda (1979)

Je polynomiální v čase. Krok velmi nepraktický (zmenšují se elipsoidy).

4.15.2 Karmarkarova projekční metoda

Začíná se v libovolném prvku množiny M , najdu simplex, vepíšu kouli ve středu x_0 , sestavím potenciálovou funkci, hledám extrém nelineární úlohy.

4.15.3 Metody konvexního programování

Například gradientní metody, metoda vnitřního bodu,...

4.16 2. základní věty lineárního programování: princip duality

Nechť (P) značí úlohu:

$$\max_{M_1} \mathbf{c}^T \mathbf{x} \quad M_1 = \{\mathbf{x} \in \mathbb{R}^n | A\mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq 0\}, \mathbf{c} \in \mathbb{R}^n, \mathbf{b} \in \mathbb{R}^m, A \in \mathbb{R}^{m \times n} \quad (1)$$

a (D) značí úlohu:

$$\min_{M_2} \mathbf{b}^T \mathbf{y} \quad M_2 = \{\mathbf{y} \in \mathbb{R}^m | A^T \mathbf{y} \geq \mathbf{c}, \mathbf{y} \geq 0\} \quad (2)$$

Definice Úlohu (P) nazýváme primární, a (D) duální úlohou lineárního programování v normálním tvaru. (dualita však platí i inverzně)

Lemma (slabá věta o dualitě) Je-li M_1 a M_2 neprázdné, potom platí, že

$$\mathbf{c}^T \mathbf{x} \leq \mathbf{b}^T \mathbf{y} \quad \forall x \in M_1, y \in M_2 \quad (3)$$

Důkaz Pro libovolné $x \in M_1$ a $\mathbf{y} \in M_2$ platí:

$$A\mathbf{x} \leq \mathbf{b}, A\mathbf{y} \geq \mathbf{c} \quad (4)$$

$$x \geq 0, y \geq 0 \quad (5)$$

Po roznásobení:

$$\mathbf{y}^T A\mathbf{x} = \mathbf{x}^T A^T \mathbf{y} \leq \mathbf{b}^T \mathbf{y} \quad (6)$$

$$\mathbf{x}^T A^T \mathbf{y} \geq \mathbf{c}^T \mathbf{x} \quad (7)$$

tedy $\mathbf{c}^T \mathbf{x} \leq \mathbf{b}^T \mathbf{y}$ a Lemma je dokázáno.

Lemma Je-li $M_1, M_2 \neq \emptyset$, potom existuje konečné $\sup_{M_1} \mathbf{c}^T \mathbf{x} = M_1$ a konečné $\inf_{M_2} \mathbf{b}^T \mathbf{y} = m_2$.

Důkaz Zvolme $\mathbf{y}^1 \in M_2$, potom z prvního lemmatu

$$\mathbf{c}^T \mathbf{x} \leq \mathbf{b}^T \mathbf{y}^1 \quad \forall x \in M_1 \Rightarrow \exists m_1 \quad (8)$$

druhý případ analogicky.

Lemma Je-li M_1 neprázdné a existuje konečné supremum, potom

$$\exists \mathbf{y}_0 \in M_2 \quad \mathbf{b}^T \mathbf{y}_0 \leq m_1 \quad (9)$$

Je-li M_2 neprázdné a existuje konečné infimum, potom

$$\exists \mathbf{x}_0 \in M_1 \quad \mathbf{c}^T \mathbf{x}_0 \geq m_2 \quad (10)$$

Důkaz (bez důkazu)

Věta Je-li $M_1, M_2 \neq \emptyset$, potom:

$$\exists \max_{M_1} \mathbf{c}^T \mathbf{x} = \mathbf{c}^T \mathbf{x}^0 = \mathbf{b}^T \mathbf{y}^0 = \min_{M_2} \mathbf{b}^T \mathbf{y} \quad (11)$$

Důkaz $M_1 \cap M_2 \neq \emptyset$, tedy podle lemma 2 existuje konečné m_1, m_2 a podle lemma 3:

$$\exists \mathbf{y}^0 : \mathbf{b}^T \mathbf{y}^0 \leq m_1 \exists \mathbf{x}^0 : \mathbf{c}^T \mathbf{x}^0 \geq m_2 \quad (12)$$

Odtud podle důsledků a lemma 1:

$$\mathbf{c}^T \mathbf{x}^0 \geq m_2 \geq m_1 \geq \mathbf{b}^T \mathbf{y}^0 \geq \mathbf{c}^T \mathbf{x}^0 \quad (13)$$

Tedy

$$\mathbf{c}^T \mathbf{x}^0 = \max_{M_1} \mathbf{c}^T \mathbf{x} = \mathbf{b}^T \mathbf{y}^0 = \min_{M_2} \mathbf{b}^T \mathbf{y} \quad (14)$$

4.17 Důsledky věty o dualitě

1. Má-li jedna z duálních úloh optimální řešení, pak ho má i druhá a platí rovnost funkčních hodnot v optimálních bodech.
2. Rovnost funkčních hodnot platí právě v optimálních.

Důkaz Jestliže x_1 není optimální řešení $(P) \Rightarrow \exists \bar{\mathbf{x}} \in M_1, \mathbf{c}^T \mathbf{x}^1 < \mathbf{c}^T \bar{\mathbf{x}}$, což ale platí pro každé $\mathbf{y} \in M_2$.

3. Souvislost optimálního řešení duálních úloh.

Tvrzení Nechť x_0 je optimální řešení (P) a $x_i^0 > 0, i \in I, \mathbf{a}_j^T \mathbf{x}^0 < b_j, j \in J_1$. Potom celá množina optimálních řešení úlohy duální:

$$M_{opt}^2 = \{\mathbf{y}^0 | \mathbf{b}^T \mathbf{y}^0 = \min_{M_2} \mathbf{b}^T \mathbf{y}\} = \{\mathbf{y} \in M_2 | \mathbf{a}_i^T \mathbf{y} = \mathbf{c}_i, i \in I, y_j = 0, j \in J_1\} \quad (1)$$

Důkaz Z důsledku 2 a vzorce

$$\mathbf{c}^T \mathbf{x} \leq \mathbf{x}^T A^T \mathbf{y} = \mathbf{y}^T A \mathbf{x} \leq \mathbf{b}^T \mathbf{y} \quad (2)$$

Pro všechna optimální řešení \mathbf{y}

$$\underbrace{\mathbf{c}^T \mathbf{x}^0 = \mathbf{x}^{0T} A^T \mathbf{y}}_{(4)} = \underbrace{\mathbf{y}^T A \mathbf{x}^0 = \mathbf{b}^T \mathbf{y}}_{(5)} \quad (3)$$

$$0 = (c - A^T \mathbf{y})^T \mathbf{x}^0 = \sum_{i \in I_1} \underbrace{(\mathbf{c}_i - \mathbf{a}_i \mathbf{y})^T}_{\leq 0} \underbrace{\mathbf{x}_i^0}_{\geq 0} + \underbrace{\sum_{i \notin I_1} (\mathbf{c}_i - \mathbf{a}_i \mathbf{y})^T v x_i^0}_{=0} \Rightarrow \mathbf{c}_i = \mathbf{a}_i \mathbf{y} \quad (4)$$

$$0 = \mathbf{y}^T (A \mathbf{x}^0 - \mathbf{b}) = \sum_{j \in J_1} \underbrace{(\mathbf{a}_j^T \mathbf{x}^0 - \mathbf{b}_j)}_{< 0} \underbrace{\mathbf{y}_j}_{\geq 0} + \underbrace{\sum_{j \notin J_1} (\mathbf{a}_j^T \mathbf{x}^0 - \mathbf{b}_j)}_{=0} \Rightarrow \mathbf{y}_j = 0 \quad (5)$$

Tvrzení Je-li \mathbf{y}^0 optimální řešení úlohy (D) pro které platí $\mathbf{y}_j^0 > 0, j \in J_2, \mathbf{a}_i^T \mathbf{y}^0 > \mathbf{c}_i, i \in I_2$. Potom množina všech optimálních řešení úlohy (P) má popis:

$$M_1^{opt} = \{\mathbf{x} \in M_1 | x_i = 0, i \in I_2, \mathbf{a}_j^T \mathbf{x} = b_j, j \in J_2\} \quad (6)$$

Důkaz Analogicky.

4.18 Různé typy úloh lineárního programování

- (a) $\min_{M_1} \mathbf{c}^T \mathbf{x} = -\max_{M_1} (-\mathbf{c}^T \mathbf{x}) \Rightarrow$
 $(D) - \min_{M_1^*} \mathbf{b}^T \mathbf{y}, M_2^* \{\mathbf{y} \in \mathbb{R}^m | A^T \mathbf{y} \geq -\mathbf{c}, \mathbf{y} \geq 0\}$
- (b) $\max_{M_1'} \mathbf{c}^T \mathbf{x} M_1' = \{\mathbf{x} \in \mathbb{R}^n | A \mathbf{x} \leq \mathbf{b}\}$
Zavedeme $\mathbf{x}^+ \max(\mathbf{x}, 0) \geq 0, \mathbf{x}^- = \max(-\mathbf{x}, 0) \geq 0$. Přepíšeme novou úlohu pomocí rovnosti $\mathbf{x} = \mathbf{x}^+ - \mathbf{x}^-$ v prostoru dvojnásobné dimenze. Ze dvou obrácených nerovností získáme rovnici.
- (c) $\max_{M_1''} \mathbf{c}^T \mathbf{x}, M_1'' = \{\mathbf{x} | A \mathbf{x} = \mathbf{b}, \mathbf{x} \geq 0\}$.
Což můžeme přepsat jako úlohu s dvouma obrácenými nerovnostmi (pro teorii).

4.19 Duální simplexová metoda

Řešíme dvě úlohy naráz. Začneme řešením, kde jsou splněny všechny podmínky (jsou bázecká) až na přípustnost (nezápornost proměnných) a platí: $\mathbf{c}^T \mathbf{x}^1 = \mathbf{b}^T \mathbf{y}^1$. Jediným krokem se dostaneme do přípustného řešení duální úlohy (v primární může stále být řešení nepřipustné). Následně již v duální úloze nesmíme opustit přípustná řešení a hledáme dvojce (kde se hodnoty rovnají), dokud i primární řešení není přípustné. Pokud jsou obě řešení přípustná, našli jsme minimum (podle věty o rovnosti).