

Základy spojité optimalizace

Ladislav Láška

2. března 2010

Obsah

1	Úvod	2
1.1	Úloha, cílová funkce, množina řešení	2
1.2	Dělení na jednotlivé disciplíny optimalizace	2
1.3	Motivační úloha	3
1.3.1	Lineární programování	3
1.3.2	Celočíselné programování	3
1.3.3	Nelineární programování	3
1.3.4	Parametrické programování	3
1.3.5	Vícekriteriální programování	4
1.3.6	Dynamické programování	4
2	Volný extrém	4
2.1	Postačující podmínka	4
2.2	Penalizační metody	4
2.3	Bariérové metody	5
2.4	Penalizačně-bariérové (SUMT)	5
3	Metody hledání lokálního minima	5
3.1	Gradientní	5
3.2	Newtonova metoda	6
3.3	Lemkeho metoda	6
4	Lineární programování	6

1 Úvod

1.1 Úloha, cílová funkce, množina řešení

Definice Úloha matematického programování (optimalizace) rozumíme úlohu

$$\min_{x \in M} f(x)$$

kde $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

Definice Funkci $f(x)$ nazýváme **cílovou**, účelovou, kriteriální, objektivní funkcí.

Definice Množinu M nazýváme množinou přípustných řešení. Prvek $x \in M$ nazýváme přípustným řešením optimalizační úlohy. Prvek $x_0 \in M$ nazveme optimálním řešením.

1.2 Dělení na jednotlivé disciplíny optimalizace

1. Volný extrém - $\min_M f(x)$
2. Vázaný extrém - $\min_M f(x), M \subset \mathbb{R}^n$
 - (a) Lineární programování:
 $\min_M cx, M = \{x | A_x \{=, \leq, \geq\} b\}$, kde $c \in \mathbb{R}^n, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$
 - (b) Nelineární programování:
 $\min_M f(x), M = \{x | g_j(x) < 0 (j = 1, \dots, m)\}, f, g_j : \mathbb{R}^n \rightarrow \mathbb{R}$
 - i. Konvexní a zobecněné konvexní programování - f, g_j konvexní, dále pak kvadratické a hyperbolické programování
 - ii. Nekonvexní (speciální typy)
 - (c) Celočíselné programování:
Lineární/nelineární programování, navíc podmínky pro celočíselnost $Ax * b$, aby $x \in \mathbb{N}$.
 - (d) Parametrické programování:
Lineární/nelineární programování, navíc parametr $\min_{M(U)} c(\lambda)^T x, c(x) = c + C\lambda, M(U) = \{x | A(U)x * b(U)\}$
 - (e) Vícekriteriální (vektorové) programování:
 $\min_M f(x), f(x) = \{f_1(x), \dots, f_s(x)\}$
 - (f) Dynamické programování - hledání optimální strategie
 - (g) Spojité programování (optimalizační procesy)
 - (h) Teorie her - optimální strategie dvou hráčů
 - (i) Semiinfinitní programování - nekonečně mnoho podmínek

1.3 Motivační úloha

1.3.1 Lineární programování

V_1, \dots, V_n - výrobci vyrábějící výrobek V v množstvích $a_i > 0$
 S_1, \dots, S_k - spotřebitelé požadující výrobek V v množstvích $b_j > 0$.
Známe cenu za dopravu jednotky výrobku V z V_i do S_j - $c_{i,j} \geq 0$.

Předpoklad: ceny za dopravu rostou lineárně.

Cíl: minimalizovat celkové náklady na dopravu.

Hledáme: množství $x_{i,j} \geq 0$ - kolik výrobce V_i dodá S_j .

Cílová funkce

$$f(x) = \sum_i \sum_j c_{i,j} x_{i,j} \quad (1)$$

na množině řešení

$$M = \{x_{i,j} \mid \sum_{i=1}^m x_{i,j} = b_j \forall j, \sum_{j=1}^m x_{i,j} = a_i \forall i, \sum_i a_i = \sum_j b_j, x_{i,j} \geq 0 \forall i \forall j\} \quad (2)$$

Všechno je lineární - úloha lineárního programování.

1.3.2 Celočíslené programování

Pokud nelze položky libovolně dělit (například lidi), můžeme přidat celočíselnou podmínku do množiny řešení:

$$x_{i,j} \in \mathbb{N}_0 \forall i \forall j \quad (3)$$

1.3.3 Nelineární programování

Zrušíme předpoklad lineárního růstu cen (tedy cena závisí na množství)

$$f(x) = \sum_i \sum_j c_{i,j}(x_{i,j}) x_{i,j} \quad (4)$$

$$c_{i,j} = C_{i,j} + c_{i,j} x_{i,j}$$

1.3.4 Parametrické programování

Produkce není pevná a závisí na parametru: $a_i = \lambda a'_i$. Ostatní vztahy můžou zůstat třeba jako u lineárního programování.

1.3.5 Vícekriteriální programování

Minimalizovat ceny za dopravu, maximalizovat zisky Z .

$$\min\{f(x), g(x)\} \quad (5)$$

$$f(x) = \sum_i \sum_j c_{i,j} x_{i,j} \quad (6)$$

$$g(x) = -Z(x_{i,j}) \quad (7)$$

1.3.6 Dynamické programování

Ceny závisí na rozhodnutí.

2 Volný extrém

Hledání $\min f(x)$.

2.1 Postačující podmínka

Jestliže má funkce $f(x)$ v $x_0 \in \mathbb{R}^n$ spojitě 2. parciální derivace, $\nabla f(x_0) = 0$, $\nabla^2 f(x_0)$ (Hessova matice) je pozitivně definitní, potom má reálná funkce $f(x)$ v x_0 ostré lokální minimum.

2.2 Penalizační metody

Máme úlohu

$$\min_M f(x), \quad M = \{x | g_j(x) \leq 0, j = 1, \dots, n\} \quad (1)$$

Hledáme penalizační funkci $p(x)$ vyjadřující pokutu za to, že pracujeme s $x \in M$. $p(x)$ je vytvořená z podmínek g_j a řešíme posloupnost úloh na volný extrém:

$$\min\{f(x) + \alpha_k p(x)\} \quad (2)$$

Po $p(x)$ požadujeme:

$$p(x) > 0 : \quad x \notin M \quad (3)$$

$$p(x) = 0 : \quad x \in M \quad (4)$$

$$p(x) \text{ spojitá} \quad (5)$$

Posloupnost takovýchto úloh za jistých okolností konverguje k optimálnímu řešení.

Příklad

$$\sum_{j=1}^n (g_j^+(x))^2, \quad g_j^+(x) = \max\{g_j(x), 0\} \quad (6)$$

2.3 Bariérové metody

Hledáme bariérovou funkci $b(x)$, která nám zabrání vystoupit z množiny M . Řešíme tedy posloupnost úloh:

$$\min\{f(x) + \frac{1}{\beta_k} b(x)\}, \quad \beta_k \rightarrow \infty \quad (1)$$

A po funkci $b(x)$ požadujeme:

$$b(x) \leq 0 : \quad x \in M \quad \lim_{x \rightarrow \partial M} b(x) = \infty \quad (2)$$

kde ∂M je hranice množiny.

Příklad

$$b(x) = - \sum_j \frac{1}{g_j(x)} \quad (3)$$

$$b(x) = - \sum_j \log(-g_j(x)) \quad (4)$$

2.4 Penalizačně-bariérové (SUMT)

Rozdělíme množinu $\{1 \dots m\}$ na I_1 disjunkt ní I_2 . Řešíme posloupnost úloh:

$$\min\{f(x) + \alpha_k \sum_{j \in I_1} \varphi(g_j(x)) + \frac{1}{\beta_k} \sum_{j \in I_2} \psi(g_j(x))\} \quad (1)$$

3 Metody hledání lokálního minima

3.1 Gradientní

Podle věty o přírůstku funkce funkce roste nejvíce ve směru gradientu:

$$f(x) = f(x_0) + \nabla f(x_0 + \theta(x - x_0))^T (x - x_0) \quad (1)$$

Počítáme:

$$x_{k+1} = x_k - \zeta \nabla f(x_k), \quad \text{kde } \zeta \text{ je řešením} \quad (2)$$

$$\min_{\zeta \leq 0} f(x_k - \zeta \nabla f(x_k)) \quad (3)$$

3.2 Newtonova metoda

$$f(x) \doteq f(x_k) + \nabla f(x_k)(x - x_k) + \frac{1}{2}(x - x_k)\nabla^2 f(x_k)(x - x_k) \quad (1)$$

$$\nabla f(x) = 0 \quad (2)$$

$$0 + \nabla f(x_k) + \nabla^2 f(x_k)(x - x_k) = 0 \quad (3)$$

$$x_{k+1} = x_k - \nabla f(x_k)(\nabla^2 f(x_k))^{-1} \quad (4)$$

$$x_1 = 0 \quad (5)$$

3.3 Lemkeho metoda

Nápad: vezmeme výchozí řešení x a vzdálenost ρ , metodou půlení přibližujeme.

Požadavky: $\{x | f(x) \leq f(x_1)\}$ je omezená.

Problém vhodně zvolit x_1 .

Metoda K x_1 sestavíme $x_1 + \rho e^i$ pro $\rho > 0$ a spočítáme funkční hodnoty $f(x_1 + \rho e_i)$ a porovnáme s funkční hodnotou v x_1 . Pokud:

1. $f(x_1 + \rho e_i) \geq f(x_1) \quad \forall i \Rightarrow \rho = \frac{\rho}{2}$
2. $\exists j: y := f(x_1 + \rho e_j) < f(x_1) \Rightarrow$ opakujeme pro y

4 Lineární programování

Definice Úlohou pro lineární programování v rovnicovém tvaru rozumíme úlohu:

$$\min_M c^T x, \quad M = \{x | Ax = b, x \geq 0\}, \quad (1)$$

$$\text{kde } A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, c \in \mathbb{R}^n, \text{rank}(A) = m, 1 \leq m < n, b \geq 0 \quad (2)$$

Definice Úlohou lineárního programování normálním tvaru rozumíme

$$\min_M c^T x, M = \{x | Ax \leq b, x \geq 0\}, \quad (3)$$

$$\text{kde } A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, c \in \mathbb{R}^n, n, m \geq 1 \quad (4)$$

4.1 Podprostor

Tvrzení Množina

$$R = \{x \in \mathbb{R}^n | a^T x = b, a \neq 0\} \quad (1)$$

představuje podprostor dimenze $n - 1$ nazývaný **nadrovinou**.

Důkaz Protože $a \neq 0 \Rightarrow \exists a_1 \neq 0 \Rightarrow x_1 = \frac{b}{a_1} - \sum_{i=1}^n \frac{a_i}{a_1} x_i$. Tedy máme $n - 1$ LN vektorů v R .

Tvrzení Množina $R^{n-\alpha} = \{x \in \mathbb{R}^n | a_i^T x = b_i, i = 1 \dots \alpha\}$ představuje podprostor \mathbb{R}^n dimenze $n - \alpha$.

4.2 Poloprostor

Definice Pro libovolnou nadrovinu $R = \{x \in \mathbb{R}^n | a^T x = b, a \neq 0\}$ nazýváme:

1. $H^+ = \{x \in \mathbb{R}^n | a^T x > b\}$ otevřeným kladným (pravým) poloprostorem \mathbb{R}^n příslušným R .
2. $H^- = \{x \in \mathbb{R}^n | a^T x < b\}$ otevřeným záporným (levým) poloprostorem \mathbb{R}^n příslušným R .
3. $\overline{H^+} = \{x \in \mathbb{R}^n | a^T x \geq b\}$ uzavřeným kladným (pravým) poloprostorem \mathbb{R}^n příslušným R .
4. $\overline{H^-} = \{x \in \mathbb{R}^n | a^T x \leq b\}$ uzavřeným záporným (levým) poloprostorem \mathbb{R}^n příslušným R .

Tvrzení Platí:

1. $H^+ \cup H^- \cup R = \mathbb{R}^n$
2. $\overline{H^+} = H^+ \cup R, \overline{H^-} = H^- \cup R$
3. $H^+ \cap H^- = H^+ \cap R = H^- \cap R = \emptyset$

Tvrzení Platí:

$$\dim \mathcal{H}_i^+ = \dim \overline{\mathcal{H}_i^+} = n \quad (1)$$

$$\text{kde } \mathcal{H}_i^+ = \{x \in \mathbb{R}^n | x_i > 0\} \quad (2)$$

$$\overline{\mathcal{H}_i^+} = \{x \in \mathbb{R}^n | x_i \geq 0\} \quad (3)$$

Důkaz V každém takovém prostoru leží všechny jednotkové vektory.

Tvrzení Platí:

$$\dim \bigcap_{i=1}^n \overline{\mathcal{H}_i^+} = \dim \bigcap_{i=1}^n \mathcal{H}_i^+ = n \quad (4)$$

Důsledek Množina přípustných řešení lineárního programování:

$$M = \{x \mid Ax = b, x \geq 0\} \quad (5)$$

kde $b(A) = m$, $a \leq m < n$.

Taktéž lze zapsat jako:

$$M = \mathbb{R}^n - m \cap \bigcap_{i=1}^n \overline{\mathcal{H}_i^+} \quad (6)$$

Definice Každou množinu $M \subset \mathbb{R}^n$, která se dá popsat jako průnik konečného počtu nadrovin a uzavřených poloprostorů nazýváme konvexním polyedrem.